

Taller 1: Análisis Predictivo y Aprendizaje Estadística

Cristian Steven Vega Torres 79677

Universidad ECCI

Sistemas Avanzados de Producción

Docente: Fredy Alexander Orjuela López

Fecha: 1/3/2026

Introducción

El presente documento desarrolla un análisis estadístico integral del comportamiento de las ventas en función de la inversión publicitaria en los medios de **TV, Radio y Newspaper**. En una primera fase, se realiza un estudio de estadística descriptiva y análisis exploratorio de datos, examinando medidas de tendencia central, dispersión y forma de las distribuciones, así como la identificación de valores atípicos y patrones de asociación mediante correlaciones de Pearson y Spearman.

En la segunda fase, se implementa un modelo de regresión lineal múltiple con el propósito de cuantificar el impacto marginal de cada medio publicitario sobre las ventas y evaluar la bondad de ajuste del modelo. Posteriormente, se aplica la estimación matricial para reforzar la comprensión teórica del método de mínimos cuadrados.

Finalmente, en la tercera fase, se entrena un árbol de decisión para comparar su desempeño predictivo frente a la regresión lineal, analizando criterios de partición, reducción de impureza e importancia de predictores. Este enfoque comparativo permite evaluar tanto la capacidad explicativa como la precisión predictiva de distintos modelos estadísticos aplicados al contexto de marketing.

1. Fase 1: Estadística Descriptiva y Análisis Exploratorio

Medidas de tendencia central y dispersión

Variable	Mean	Median	Std	Min	Max	Skewness	Kurtosis
TV	147.0425	149.75	85.854236	0.7	296.4	-0.069853	-1.226495
Radio	23.2640	22.90	14.846809	0.0	49.6	0.094175	-1.260401
Newspa per	30.5540	25.75	21.778621	0.3	114.0	0.894720	0.649502
Sales	14.0225	12.90	5.217457	1.6	27.0	0.407571	-0.408869

Tabla [1]: esta tabla muestra las medidas de tendencia central y dispersión para las variables independientes y la variable Sales dependiente.

- Sesgo (Skewness) y Curtosis (Medidas de forma).

Valor de Skewness	Tipo de sesgo	Interpretación
-0.069853	Negativo muy leve	Distribución casi simétrica
0.094175	Positivo muy leve	Distribución casi simétrica
0.894720	Positivo moderado	Cola derecha marcada
0.407571	Positivo leve	Ligera asimetría derecha

Tabla [2]: esta tabla refleja el sesgo de Skewness y su interpretacion

Curtosis	Tipo de distribución	Clasificación	Interpretación
-1.226495	Platicúrtica	Curtosis negativa	Distribución aplanada, con baja concentración de datos alrededor de la media y colas poco pronunciadas; baja presencia de valores extremos.
-1.260401	Platicúrtica	Curtosis negativa	Distribución aplanada, con dispersión uniforme de los datos y escasa probabilidad de valores extremos.
0.649502	Leptocúrtica	Curtosis positiva	Alta concentración de datos en torno a la media y colas pesadas; mayor probabilidad de valores extremos.
-0.408869	Ligeramente platicúrtica	Curtosis negativa leve	Distribución cercana a la normal, con dispersión moderada y sin presencia significativa de valores extremos.

Tabla [3]: La tabla presenta la interpretación de los valores de curtosis como medida de forma de la distribución de las variables analizadas. Valores negativos indican distribuciones platicúrticas (más planas que la normal), valores positivos indican distribuciones leptocúrticas (más concentradas alrededor de la media y con colas más pesadas), y valores cercanos a cero representan distribuciones mesocúrticas (similares a la distribución normal).

Análisis de Distribución y Atípicos




Figura [1]: En la superior de la gráfica encontramos los histogramas de las variables Tv, radio y newspaper, en la parte inferior vemos el diagrama de caja para cada variable

Las distribuciones mostradas en los histogramas y boxplots revelan diferentes grados de simetría, con TV y Sales más cercanas a la simetría, mientras que Radio y Newspaper son marcadamente asimétricas.

Simetría de Distribuciones

TV: Simétrica o ligeramente bimodal, con histograma equilibrado alrededor de la mediana (~150 en boxplot); densidad uniforme sin sesgo claro.

Radio: Asimétrica positiva (sesgada a la derecha), pico en bajos valores (0-10), cola larga hacia 40-50.

Newspaper: Fuertemente asimétrica positiva, concentración masiva cerca de 0 y cola extendida hasta ~100.

Sales: Aproximadamente simétrica, histograma en forma de campana centrada en 10-15, boxplot compacto sin sesgo evidente.

Datos Atípicos

Sí, se identifican outliers significativos, principalmente en Newspaper (puntos altos en boxplot ~90-100, alejados del IQR ~0-20) y Radio (outliers ~40-50). TV muestra posibles bajos outliers, pero menos extremos; Sales no tiene outliers visibles.

Influencia en Regresión Lineal

Estos outliers pueden distorsionar la línea de regresión al jalarla hacia sí (efecto de palanca), inflando pendientes o interceptos y subestimando varianza en la mayoría de datos. Por ejemplo, altos gastos en Newspaper sin ventas proporcionales crearían residuales grandes, sesgando coeficientes y reduciendo R^2 ; se mitiga con transformaciones (log) o modelos robustos.

Evaluación de Asociación: Calcule y presente las matrices de correlación de Pearson Spearman.




Figura [2]: Esta matriz de correlación de Pearson nos identifica la relación que tienen las variables del eje X con las variables del eje Y, siendo 1 la relación más alta y 0 una relación muy débil




Figura [3]: Esta matriz de correlación de Spearman nos identifica la relación que tienen las variables del eje X con las variables del eje Y, siendo 1 la relación más alta y 0 una relación muy débil

- **¿Qué significa un coeficiente cercano a 1 o -1 en el contexto de la inversión publicitaria y el retorno en ventas?**

Un coeficiente de correlación cercano a 1 indica una relación positiva muy fuerte, lo que significa que a medida que aumenta la inversión publicitaria, las ventas también aumentan de forma consistente. En términos prácticos, implica que la inversión en el medio publicitario analizado es un buen predictor del crecimiento en ventas.

Por el contrario, un coeficiente cercano a -1 indicaría una relación negativa fuerte, es decir, que, al aumentar la inversión publicitaria, las ventas disminuirían, lo cual sería un comportamiento inverso y poco común en contextos de marketing.

En este estudio, valores como 0.78 (Pearson) y 0.80 (Spearman) para TV-Sales reflejan una asociación fuerte, lo que justifica el uso de modelos predictivos como la regresión lineal para estimar el retorno en ventas.

- **¿Cómo se interpreta un valor de correlación cercano a 0?**

Un valor de correlación cercano a 0 indica ausencia de relación significativa entre las variables, es decir, que los cambios en la inversión publicitaria no están asociados de forma sistemática con cambios en las ventas.

Esto implica que la variable no tiene capacidad predictiva sobre la otra. En el contexto del estudio, relaciones como TV-Radio (0.05) o TV-Newspaper (0.06) muestran que las inversiones en esos medios son estadísticamente independientes, sin relación relevante entre sí ni influencia mutua directa.

- **Compare ambos coeficientes (Pearson y Spearman). ¿Sugieren estos resultados que las relaciones son estrictamente lineales? Justifique su respuesta basándose en la forma de la nube de puntos observada.**

TV – Sales ($r = 0.78$ Pearson; $\rho = 0.80$ Spearman)

Se evidencia una **correlación positiva fuerte**, donde el valor de Spearman ligeramente superior al de Pearson indica una relación **muy sólida y mayormente lineal**, con una tendencia general estable, lo que justifica estadísticamente el uso de un **modelo de regresión lineal** para la predicción de las ventas a partir de la inversión en televisión.

Radio – Sales ($r = 0.58$ Pearson; $\rho = 0.55$ Spearman)

Se identifica una **correlación positiva moderada**, con valores similares entre Pearson y Spearman, lo que sugiere una relación **predominantemente lineal**, aunque de menor intensidad, indicando que la inversión en radio influye en las ventas, pero con un poder explicativo inferior al de la televisión.

Newspaper – Sales ($r = 0.23$ Pearson; $\rho = 0.19$ Spearman)

Se observa una **correlación positiva débil**, con baja concordancia entre Pearson y Spearman, lo que indica una relación **poco significativa y de escasa capacidad predictiva**, por lo cual la inversión en prensa no constituye un predictor relevante del comportamiento de las ventas.

TV – Radio ($r = 0.05$ Pearson; $\rho = 0.06$ Spearman)

Los coeficientes muestran una **correlación prácticamente nula**, evidenciando **independencia estadística** entre ambas variables, sin relación lineal ni monotónica significativa entre la inversión en televisión y radio.

TV – Newspaper ($r = 0.06$ Pearson; $\rho = 0.05$ Spearman)

Se presenta una **correlación despreciable**, lo que indica **ausencia de relación estadísticamente significativa**, confirmando que las inversiones en televisión y prensa se comportan como variables independientes.

Radio – Newspaper ($r = 0.35$ Pearson; $\rho = 0.32$ Spearman)

Se evidencia una **correlación positiva baja-moderada**, lo que sugiere una relación débil pero consistente, indicando una **ligera asociación** entre la inversión en radio y prensa, sin dependencia estructural fuerte entre ambas variables.

2. Fase 2: Regresión Lineal y Diagnóstico

Los coeficientes provienen de una regresión lineal múltiple típica del dataset de publicidad (Sales ~ TV + Radio + Newspaper), donde Sales es la variable dependiente (ventas en miles) y los predictores son gastos en cada medio (en miles de dólares).

Ecuación del Modelo

La ecuación estimada es:

$$\text{Sales} = 2.9389 + 0.0458 \times \text{TV} + 0.1885 \times \text{Radio} - 0.0010 \times \text{Newspaper}$$

Interpretación del Intercepto ($\beta_0 = 2.9389$)

Representa las ventas esperadas cuando todos los gastos publicitarios son cero (TV = Radio = Newspaper = 0). Así, se esperan unas 2.94 unidades de ventas basales, sin publicidad. Este valor tiene sentido contextual pero rara vez es directamente interpretable en práctica.

Interpretación de Pendientes ($\beta_1, \beta_2, \beta_3$)

Cada coeficiente indica el cambio esperado en Sales por cada unidad adicional (1 millar de dólares) en ese predictor, manteniendo los otros constantes:

TV ($\beta_1 = 0.0458$): +0.046 ventas por cada \$1k extra en TV. Relación positiva moderada.

Radio ($\beta_2 = 0.1885$): +0.189 ventas por cada \$1k extra en Radio. Efecto más fuerte que TV.

Newspaper ($\beta_3 = -0.0010$): -0.001 ventas por cada \$1k extra en Newspaper. Efecto negativo nulo/prácticamente insignificante, sugiriendo no aporte o posible multicolinealidad.

Consideraciones

Estos son efectos marginales ceteris paribus. Para evaluar significancia, revisar p-valores y R^2 (no proporcionados); el signo negativo en Newspaper alinea con distribuciones sesgadas y outliers observados previamente.




Figura [4]: Gráfico de Regresión Lineal entre Inversión en Publicidad y Ventas




Figura [5]: Gráfico de Regresión Lineal entre Inversión en radio y Ventas




Figura [6]: Gráfico de Regresión Lineal entre Inversión en Newspaper y Ventas

- **Análisis de Bondad de Ajuste:** Calcule el coeficiente de determinación R^2 . Indique que proporción de la variabilidad total de las ventas es explicada por el modelo y analice si la inclusión de la variable Radio y Newspaper mejoró significativamente el ajuste respecto al modelo simple de la Fase 1.

El R^2 de 0.8972 indica un excelente ajuste del modelo de regresión lineal múltiple a los datos de ventas.

Coeficiente de Determinación

El R-cuadrado mide la proporción de la variabilidad total en las ventas explicada por los predictores (TV, Radio, Newspaper). Un valor de 0.8972 significa que el modelo explica el 89.72% de la varianza en las ventas; solo el 10.28% queda sin explicar (error residual). Esto refleja una predicción muy precisa para este dataset clásico de publicidad.[ppl-ai-file-upload.s3.amazonaws]

Mejora respecto al Modelo Simple

Sí, incluir Radio y Newspaper mejoró significativamente el ajuste comparado con un modelo simple (solo TV). Típicamente, el modelo univariado TV-Sales tiene $R^2 \approx 0.61-0.70$, mientras que el múltiple sube a 0.90 gracias a Radio ($\beta=0.1885$, fuerte aporte). Newspaper ($\beta \approx 0$) añade poco directamente pero contribuye al ajuste global vía varianza explicada combinada; la ganancia de ~20-30% en R^2 justifica la inclusión multivariable.[ppl-ai-file-upload.s3.amazonaws]

Análisis de Bondad de Ajuste

Fortalezas: R^2 alto (>0.89) indica robustez predictiva; modelo captura patrones principales de gastos publicitarios.

Limitaciones: Alto R^2 no garantiza causalidad; revisar residuos, multicolinealidad (posible entre medios) y significancia F-global para validación completa.

- **4. Estimación Matricial: Considere el siguiente conjunto de 5 observaciones para una regresión lineal simple. Utilizando la formulación matricial $\hat{\beta} = (X'X)^{-1}X'Y$, encuentre los estimadores $\hat{\beta}_0$ (intercepto) y $\hat{\beta}_1$ (pendiente). Dadas las matrices de diseño X y el vector de respuesta Y :**

$$X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}, \quad Y = \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix}$$

Tarea:

- Calcule la matriz transpuesta X' .
- Calcule el producto $X'X$ y su respectiva matriz inversa $(X'X)^{-1}$.
- Calcule el producto $X'Y$.
- Obtenga el vector de parámetros $\hat{\beta}$ y escriba la ecuación de la recta estimada $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$.

$$x = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}, \quad y = \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix}$$

- Calcule la matriz transpuesta X'

$$X' = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix}$$

- Calcule el producto $x'x$ y su respectiva matriz inversa $(x'x)^{-1}$

$$X'X = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} \cdot \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix} \quad \begin{matrix} 2 \times 5 \\ 5 \times 2 \end{matrix} \quad X'X = \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix} A$$

$$(X'X)^{-1} = \frac{(\text{Adjunta } A)^T}{\text{determinante } A} \quad \text{determinante } A = 5 \times 55 - 15 \times 15 = 275 - 225 = 50$$

$$\text{Adjunta transpuesta} = \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix}$$

$$(X'X)^{-1} = \frac{1}{50} \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix} = \begin{pmatrix} \frac{55}{50} & \frac{-15}{50} \\ \frac{-15}{50} & \frac{5}{50} \end{pmatrix} = \begin{pmatrix} 1,1 & -0,3 \\ -0,3 & 0,1 \end{pmatrix} = (X'X)^{-1}$$

- Calcule el producto $x'y$

$$x'y = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix} = \begin{pmatrix} 2+4+6+7+9 \\ 1(2)+2(4)+3(6)+4(7)+5(9) \end{pmatrix} = \begin{pmatrix} 28 \\ 101 \end{pmatrix}$$

Imagen [1]: Se desarrollan las transformaciones de las matrices

• Obtenga el vector de parámetros $\hat{\beta}$ y escriba la ecuación de la recta estimada $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

$$= \frac{1}{50} \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix} \begin{pmatrix} 28 \\ 101 \end{pmatrix} = \begin{pmatrix} 55(28) - 15(101) \\ -15(28) + 5(101) \end{pmatrix} = \begin{pmatrix} 25 \\ 85 \end{pmatrix}$$

$$\hat{\beta} = \frac{1}{50} \begin{pmatrix} 25 \\ 85 \end{pmatrix} = \begin{pmatrix} 0,5 \\ 1,7 \end{pmatrix} = \hat{\beta}_0, \hat{\beta}_1$$

$$\hat{y} = 0,5 + 1,7 x$$

Imagen [2]: Se realiza la ecuación de la recta a partir de las matrices

5. Fase 3: Árboles de Decisión y Comparación de Modelos

Entrenamiento del Modelo: Utilizando las variables TV y Radio, entrene un árbol de regresión para predecir las ventas (Sales). Grafique la estructura del árbol y explique bajo que criterio se realizan las particiones en los nodos.

Estructura del Árbol de Regresión: Ventas vs (TV y radio)




Figura [7]: Estructura del Árbol de Regresión: Ventas vs. TV y Radio

Este árbol de regresión explica cómo las variables de inversión en TV y Radio afectan el valor de las Ventas.

Variable más influyente (Nodo Raíz): La inversión en TV es el principal predictor. El primer corte se hace en 122.05. Si la inversión es menor o igual a este monto, las ventas promedio esperadas caen significativamente (\$14.02 \to 9.78\$).

Interacción de variables: El modelo muestra que para niveles altos de inversión en TV ($> \$122.05$), la variable Radio se vuelve el factor determinante para maximizar ventas.

Escenario Óptimo: El valor de ventas más alto (21.95) se alcanza cuando la inversión en TV es mayor a 122.05 y además es mayor a 194.55, combinado con una inversión en radio significativa.

Escenario Mínimo: Las ventas más bajas (4.67) ocurren cuando la inversión en TV es mínima (≤ 8.65).

Precisión: El `squared_error` (error cuadrático) disminuye conforme bajamos en el árbol, lo que indica que las predicciones en las "hojas" finales son mucho más precisas que el promedio inicial.

1. Criterio de Suma de Errores Cuadráticos (SSE)

El algoritmo busca reducir la impureza del nodo. En regresión, la impureza se mide comúnmente con el Error Cuadrático Medio (MSE) o el Error Cuadrático Sumado (SSE).

Para cada nodo, el modelo calcula el promedio de las ventas (value).

El `squared_error` que ves en tu imagen representa la desviación de los datos respecto a ese promedio.

La regla de oro: Se elige la partición que produce la mayor reducción en el error total al comparar el nodo padre con la suma de los errores de los nodos hijos.

2. Selección del Punto de Corte Óptimo

El árbol no elige valores al azar. Realiza un proceso competitivo:

Evaluación de Variables: Prueba todas las variables predictoras (en tu caso, TV y radio).

Búsqueda de Umbral: Para cada variable, el algoritmo prueba todos los valores posibles de los datos como puntos de corte (por ejemplo, el corte de 122.05 en el nodo raíz).

Maximización de Ganancia: Selecciona la combinación de variable + umbral que minimice el error cuadrático en las ramas resultantes.

3. Naturaleza Binaria y Recursiva

Binaria: Cada nodo se divide exactamente en dos ramas: True (izquierda, si cumple la condición) y False (derecha, si no la cumple). Por ejemplo, si $TV \leq 122.05$ es cierto, los datos se mueven al nodo de la izquierda con un promedio de ventas de 9.78.

Recursiva: Este proceso se repite en cada nuevo nodo hijo hasta que se alcanza un criterio de parada (como el número mínimo de muestras por nodo o una profundidad máxima).

Análisis de un nodo específico (Ejemplo):

En el nodo raíz de tu imagen:

Antes del corte: El error es 27.09 con 200 muestras.

Después del corte ($TV \leq 122.05$): Los datos se separan en un grupo de 83 muestras (ventas bajas) y otro de 117 (ventas más altas).

Resultado: El `squared_error` en el nodo de la izquierda baja drásticamente a 7.98, lo que indica que la partición fue muy efectiva para agrupar comportamientos similares.

- Cálculo Manual de Incertidumbre (Clasificación)

Suponga una versión simplificada del problema donde las ventas se categorizan en “Altas” y “Bajas” Con los siguientes datos de 4 mercados, calcule la reducción de la incertidumbre:

Mercado	Inversión TV	Ventas (Clase)
1	Alta	Altas
2	Alta	Altas
3	Baja	Bajas
4	Baja	Altas

Tareas:

- Calcule la Entropía del Nodo Padre: $H(S) = - \sum p_i \log_2(p_i)$.
- Calcule el índice de Gini para el nodo padre: $Gini = 1 - \sum p_i^2$.
- Determine la Ganancia de Información tras realizar una partición por la variable Inversión TV.

Cálculo Manual de Incertidumbre (Clasificación)

Basándonos en la tabla de 4 mercados proporcionada:

Ventas Altas (P1): 3 de 4 (75% o 0.75).

Ventas Bajas (P2): 1 de 4 (25% o 0.25).

A. Entropía del Nodo Padre

La fórmula es $H(S) = - \sum p_i \log_2(p_i)$.

$$H(S) = - (0.75 * \log_2(0.75) + 0.25 * \log_2(0.25))$$

$$H(S) = - (-0.311 - 0.5) = \mathbf{0.811}$$

B. Índice de Gini para el Nodo Padre

La fórmula es $Gini = 1 - \sum P_i^2$.

$$Gini = 1 - (0.75^2 + 0.25^2)$$

$$Gini = 1 - (0.5625 + 0.0625) = \mathbf{0.375}$$

C. Ganancia de Información (Partición por Inversión TV)

Si dividimos por "Inversión TV":

Nodo Izquierdo (TV Alta): 2 mercados, ambos con Ventas Altas. Entropía = 0.

Nodo Derecho (TV Baja): 2 mercados, uno Alta y uno Baja. Entropía = 1.0 (máxima incertidumbre).

$$\text{Entropía Ponderada: } (2/4 \cdot 0) + (2/4 \cdot 1) = 0.5$$

$$\text{Ganancia: } 0.811 - 0.5 = \mathbf{0.311}$$

3. Importancia de Predictores: Identifique que variable tiene mayor peso en el árbol de decisión y compárela con los coeficientes obtenidos en la regresión múltiple de la Fase 2.

Al observar la estructura del árbol de regresión:

Variable Principal: La Inversión en TV es el predictor más importante, ya que se encuentra en el "Nodo Raíz" (la primera decisión).

Comparación: En una regresión múltiple, el coeficiente de TV suele ser el más alto. Aquí, el árbol confirma esa jerarquía al realizar la primera partición en $TV \leq 122.05$

para explicar la mayor parte de la varianza inicial (\$27.09\$).

Variable Secundaria: El Radio actúa como un refinador de la predicción una vez que la inversión en TV ya está definida.

4. Diagnóstico Comparativo: Discuta en que escenarios sería preferible utilizar un modelo de regresión lineal frente a un árbol de decisión, considerando la interpretabilidad y la precisión del pronóstico.

La elección entre estos modelos depende de la naturaleza de tus datos y del objetivo de negocio (entender la tendencia o definir reglas de operación).

1. Escenarios para Regresión Lineal

Es preferible utilizar el modelo de la primera imagen (Regresión Lineal Simple) cuando:

Tendencia Global: Necesitas entender la relación promedio y constante entre variables. Por ejemplo, cuánto aumenta la venta por cada dólar adicional invertido en TV de forma lineal.

Interpolación y Extrapolación: Deseas predecir valores en puntos donde no tienes datos, asumiendo que el comportamiento seguirá la misma pendiente.

Interpretabilidad Estadística: Buscas métricas de ajuste global como el R^2

(que en tu gráfico es 0.612) para validar qué tanta variabilidad total explica el modelo.

Simplicidad: Los datos muestran una nube de puntos con una dirección clara y sin cambios bruscos de comportamiento.

2. Escenarios para Árbol de Decisión

Es preferible utilizar el modelo de la segunda imagen (Árbol de Regresión) cuando:

Segmentación Operativa: Necesitas reglas claras de "Si-Entonces" para la toma de decisiones. Por ejemplo: "Si la inversión en TV es ≤ 122.05

, la expectativa de venta es baja (9.78)".

Relaciones No Lineales: Los datos presentan "saltos" o umbrales críticos donde el comportamiento cambia drásticamente, algo que una línea recta no puede capturar.

Interacciones entre Variables: Deseas ver cómo una variable afecta a la otra. El árbol muestra que el impacto del Radio cambia dependiendo de cuánta TV se haya invertido previamente.

Manejo de Outliers: Los árboles suelen ser más robustos ante valores extremos, ya que aíslan esos datos en hojas específicas en lugar de permitir que desvíen toda la pendiente de una línea.

Criterio	Regresión Lineal	Árbol de Decisión
Interpretabilidad	Alta (Ecuación): Te da una fórmula matemática única ($y = mx + b$)	Alta (Visual): Te da un mapa de decisiones fácil de seguir para personal no técnico.
Precisión	Mayor si la relación entre inversión y ventas es proporcional y constante.	Mayor si existen "puntos de quiebre" o interacciones complejas entre TV y Radio.
Flexibilidad	Rígida; asume que el efecto de la publicidad es siempre el mismo.	Flexible; puede adaptarse a comportamientos locales dentro de los datos.

Tabla [4]: medidas de Árbol de decisión

En conclusión, si buscas optimizar el presupuesto identificando umbrales de éxito (como el nodo de ventas de 21.95), el Árbol de Decisión es superior. Si buscas proyectar el crecimiento anual basado en una tendencia estable, la Regresión Lineal es la herramienta adecuada.

Conclusión

En el presente análisis, tanto la regresión lineal múltiple como el árbol de decisión demostraron capacidad para modelar la relación entre la inversión publicitaria (TV, Radio y Newspaper) y las ventas. Sin embargo, para este caso particular, la regresión lineal múltiple resulta más robusta como modelo predictivo principal.

El modelo lineal alcanzó un R^2 de 0.8972, lo que indica que explica aproximadamente el 89.72% de la variabilidad total de las ventas. Además, los coeficientes estimados muestran coherencia con el análisis exploratorio previo: TV y Radio presentan efectos positivos significativos, mientras que Newspaper tiene un impacto prácticamente nulo. La similitud entre los coeficientes de correlación de Pearson y Spearman, especialmente en la relación TV–Sales, sugiere que la relación es mayormente lineal, lo que favorece el uso de regresión.

Por su parte, el árbol de decisión ofrece ventajas importantes en términos de interpretabilidad operativa, ya que genera reglas claras de segmentación (por ejemplo, puntos de corte específicos en la inversión en TV). También es más flexible ante posibles relaciones no lineales y menos sensible a valores atípicos. Sin embargo, en este conjunto de datos no se evidencian cambios bruscos o umbrales críticos suficientemente fuertes como para superar la precisión global del modelo lineal.

En conclusión, dado que:

- Las relaciones observadas son predominantemente lineales,
- El modelo lineal presenta un ajuste alto y estable,
- No se identifican patrones no lineales complejos dominantes,

La regresión lineal múltiple es el modelo más robusto y eficiente para este caso específico.

No obstante, el árbol de decisión complementa el análisis al aportar una perspectiva estratégica basada en segmentación, por lo que ambos modelos pueden considerarse herramientas complementarias: la regresión para predicción cuantitativa precisa y el árbol para apoyo en decisiones tácticas de inversión publicitaria.