

Taller 2: Redes Neuronales

Cristian Steven Vega Torres 79677

Universidad ECCI

Sistemas Avanzados de Producción

Docente: Fredy Alexander Orjuela López

Fecha: 11/04/2026

Contenido

Fase 1 5

Respuestas preguntas fase 1 5

Fase 2 7

Incrementando el Learning_rate a 0.8 8

Disminuyendo el Learning_rate a (10^{-8}) 9

Respuestas a las Preguntas: Fase 2 11

1. Dependencia del Punto Inicial 11

2. El fenómeno de "Overshooting" 11

3. Eficiencia Computacional 11

Fase 3 12

Vista rapida (head)12

Fase 3: Análisis Avanzado de Resultados (MLP) 18

A. Diferenciación de Métricas: MAE vs. RMSE..... 18

Análisis de Severidad: 18

B. Diagnóstico de Desempeño: El Fenómeno del Sobreajuste 19

Análisis de Severidad 20

B. Diagnóstico de Desempeño: El Fenómeno del Sobreajuste 20

C. Interpretación de Residuos: Sesgos en Ventas/Alquileres Altos 21

Fase 4 22

Fase 5 25

Respuesta de preguntas 31

Ajuste de Pesos de Clase y Entrenamiento de la Red Neuronal 31

La Trampa de la Exactitud en Datos Desbalanceados 32

Cálculo de Métricas y Análisis de Costos 32

Precision (Precisión) 32

Recall (Sensibilidad)..... 33

Respuesta 33

Figura 1 Visualización del algoritmo de descenso del gradiente en una superficie tridimensional y curvas de nivel 7

Figura 2 Comportamiento del descenso del gradiente con un learning rate de 0.8 8

Figura 3 Comportamiento del descenso del gradiente con un learning rate de (10^{-8}) . 9

Figura 4 Trayectoria del descenso del gradiente iniciando en el punto (6, -6) 10

Figura 5 Resumen estadístico del conjunto de datos de bicicletas compartidas 13

Figura 6 Perfil estadístico detallado de la variable 'instant' 13

Figura 7 Perfil estadístico de las variables temporales 'dteday' y 'season' 14

Figura 8 Distribución de frecuencias para las variables cnt (conteo total) y temp (temperatura) 14

Figura 9 Distribución de frecuencias para las variables atemp (sensación térmica) y hum (humedad) 15

Figura 10 Tendencias promedio de alquiler de bicicletas por hora y día de la semana 16

Figura 11 Gráfico de dispersión de valores reales vs. predichos (Conjunto de Test) mediante un modelo MLP 16

Figura 12 Distribución de los residuales del modelo MLP en el conjunto de prueba 17

Figura 13 Curva de pérdida del modelo MLP durante la fase de entrenamiento 17

Figura 15 Análisis de distribución de clases 27

Figura 16 Análisis de variables Torque VS Velocidad Rotacional en los sensores 27

Figura 17 Distribución de la temperatura del aire y su relación con la falla de maquinaria 28

Figura 18 Distribución de la temperatura del proceso según el estado de falla de la maquinaria 28

Figura 19 Matriz de confusión del modelo Random Forest para la clasificación de fallos 29

Figura 20 Gráfico de importancia de las variables para el modelo Random Forest 30

Imagen 1 Fase 1 5

Imagen 2 12

Imagen 3 fase 4 22

Imagen 4 Fase 4.2 23

Imagen 5 Fase 4.3 24

Imagen 6 Fase 4.5 25

INTRODUCCIÓN

El presente trabajo aborda el análisis y aplicación de modelos de aprendizaje automático enfocados en la optimización y predicción en contextos industriales, específicamente en problemas de demanda de bicicletas y mantenimiento predictivo de maquinaria. A través del desarrollo de cinco fases, se exploran tanto los fundamentos matemáticos como las implicaciones prácticas de técnicas como la regularización Ridge, el descenso del gradiente y las redes neuronales artificiales.

Inicialmente, se analiza el problema de la multicolinealidad y la estabilidad numérica en modelos de regresión, introduciendo la regularización como mecanismo de control del

sobreajuste. Posteriormente, se estudia el comportamiento del algoritmo de descenso del gradiente, evaluando su sensibilidad frente a la tasa de aprendizaje y el punto de inicialización, aspectos clave en la convergencia de modelos de optimización.

En fases posteriores, se emplean modelos de redes neuronales tipo Perceptrón Multicapa (MLP) para la predicción de la demanda de bicicletas, complementado con un análisis estadístico del conjunto de datos. Finalmente, se aborda un caso aplicado de mantenimiento predictivo utilizando modelos de clasificación como Random Forest, destacando la importancia de métricas avanzadas en escenarios con datos desbalanceados.

El objetivo principal de este trabajo es no solo evaluar el desempeño técnico de los modelos, sino también interpretar sus resultados en un contexto empresarial, permitiendo la toma de decisiones informadas orientadas a la optimización de recursos y la reducción de costos operativos.

Fase 1

Fase 1

función costo

$$J(\beta) = \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

forma matricial

$$J(\beta) = (y - X\beta)^T (y - X\beta) + \lambda \beta^T \beta$$

Expanción de la forma cuadrática

$$\begin{aligned} & (y - X\beta)^T (y - X\beta) \\ &= y^T y - 2\beta^T X^T y + \beta^T X^T X \beta \\ J(\beta) &= y^T y - 2\beta^T X^T y + \beta^T X^T X \beta + \lambda \beta^T \beta \end{aligned}$$

Condición de primer orden

$$\frac{\partial J(\beta)}{\partial \beta}$$

Derivando término a término

- * $y^T y \rightarrow 0$
- * $-2\beta^T X^T y \rightarrow -2X^T y$
- * $\beta^T X^T X \beta \rightarrow 2X^T X \beta$
- * $\lambda \beta^T \beta \rightarrow 2\lambda \beta$

entonces

$$\frac{\partial J(\beta)}{\partial \beta} = -2X^T y + 2X^T X \beta + 2\lambda \beta$$

igualar a 0 $\rightarrow -2X^T y + 2X^T X \beta + 2\lambda \beta = 0$

Dividir todo entre 2 $X^T X \beta + \lambda \beta = X^T y$

Solución cerrada

Factorizamos $(X^T X + \lambda I) \beta = X^T y$

Despejamos $\hat{\beta}_{\text{ridge}} = (X^T X + \lambda I)^{-1} X^T y$

Imagen 1 Fase 1

Respuestas preguntas fase 1

La matriz $X^T X$ puede no ser invertible cuando existe multicolinealidad o cuando el número de variables es mayor que el número de observaciones ($p > n$). En estos casos, dicha

matriz es singular o mal condicionada, lo que impide calcular el estimador de mínimos cuadrados ordinarios.

La regularización Ridge soluciona este problema al añadir el término λI , obteniendo:

$$X^T X + \lambda I$$

Este término tiene un efecto clave: incrementa los valores propios de la matriz $X^T X$ en una cantidad $\lambda > 0$. Como resultado, la nueva matriz se vuelve definida positiva, lo que garantiza que todos sus valores propios sean estrictamente positivos.

Dado que una matriz definida positiva siempre es invertible, se concluye que:

La suma $X^T X + \lambda I$ asegura la existencia de la inversa, incluso si $X^T X$ es singular.

Cuando λ tiende a cero, la penalización desaparece y el estimador Ridge se aproxima al de mínimos cuadrados ordinarios:

$$\hat{\beta}_{Ridge} = (X^T X + \lambda I)^{-1} X^T Y$$

En este caso:

- El modelo se ajusta fuertemente a los datos
- Los coeficientes pueden tomar valores grandes
- Se obtiene bajo sesgo

Pero alta varianza, lo que aumenta el riesgo de sobreajuste

Cuando λ crece mucho:

- La penalización domina la función de costo
- Los coeficientes β tienden a valores cercanos a cero
- El modelo se vuelve más simple

Consecuencias:

- Alto sesgo (pierde capacidad de ajuste)
- Baja varianza (más estabilidad frente a nuevos datos)
- Posible subajuste

Conclusión Analítica

El parámetro λ introduce un trade-off entre sesgo y varianza:

Valores pequeños $\rightarrow$ modelos complejos (riesgo de sobreajuste)

Valores grandes $\rightarrow$ modelos simples (riesgo de subajuste)

Por tanto, la elección adecuada de λ permite encontrar un equilibrio óptimo que minimiza el error de predicción.

Fase 2

Ubique el último bloque de código donde se configura la simulación:

```
# --- CONFIGURACIÓN DE LA SIMULACIÓN ---  
start_point = [0.0, 0.1]    # Punto de inicio  
learning_rate = 0.0001      # Tasa de aprendizaje (eta)  
num_iterations = 1000       # Número de pasos
```




Figura 1 Visualización del algoritmo de descenso del gradiente en una superficie tridimensional y curvas de nivel

La imagen de la izquierda muestra la trayectoria del descenso del gradiente sobre la superficie de la función de costo $f(x, y)$ en un espacio 3D. La imagen de la derecha representa

la proyección de dicha trayectoria sobre un mapa de curvas de nivel (contour plot), donde los colores indican los valores de la función.

Incrementando el Learning_rate a 0.8




Figura 2 Comportamiento del descenso del gradiente con un learning rate de 0.8

La figura muestra el impacto de una tasa de aprendizaje elevada en la optimización de la función. A diferencia de una trayectoria convergente, se observa un sobreimpulso (*overshooting*) donde los pasos exceden la región del mínimo global. Elaboración propia (o citar fuente original si aplica).

Análisis de la Trayectoria

Al aumentar el learning rate a 0.8, has entrado en un terreno peligroso para la estabilidad del algoritmo. Esto es lo que sucede:

¿Qué sucede con la trayectoria?

La trayectoria se ha vuelto errática y agresiva. En lugar de seguir la dirección del gradiente negativo de forma suave hacia el fondo del "valle", el algoritmo está dando saltos tan

grandes que "rebota" de un lado a otro de las paredes de la función. Los pasos son tan amplios que superan el punto mínimo en cada iteración.

¿Logra llegar al centro o comienza a oscilar/divergir?

No logra llegar al centro: El algoritmo es incapaz de establecerse en el punto óptimo porque su "zancada" es más grande que el área del mínimo mismo.

Divergencia/Oscilación: En la imagen de las curvas de nivel se observa claramente que la trayectoria diverge. En lugar de cerrarse hacia el origen (0,0), la línea roja se dispara hacia afuera de los límites del gráfico.

Disminuyendo el Learning_rate a (10^{-8})




Figura 3 Comportamiento del descenso del gradiente con un learning rate de (10^{-8}).

Reduzca el learning rate a un valor extremadamente pequeño (10^{-8}). Observe el resultado tras 1000 iteraciones. ¿Es suficiente este tiempo de computo para alcanzar el minimo?

No, 1000 iteraciones no son suficientes para alcanzar el mínimo cuando el learning rate es extremadamente pequeño (10^{-8}).

Como se observa en la imagen, tanto en la gráfica 3D como en la proyección de curvas de nivel, la trayectoria del descenso del gradiente (línea roja) muestra un avance prácticamente

imperceptible desde el punto inicial. El punto actual (marcado en verde) permanece muy lejos de las zonas donde se encuentran los mínimos (regiones más oscuras en las curvas de nivel).

Esto ocurre porque un learning rate tan bajo produce actualizaciones muy pequeñas en cada iteración, haciendo que el algoritmo progrese de manera extremadamente lenta. Aunque teóricamente podría llegar al mínimo, en la práctica requeriría un número muy elevado de iteraciones, mucho mayor que 1000.




Figura 4 Trayectoria del descenso del gradiente iniciando en el punto (6, -6)

La figura ilustra cómo el punto de partida condiciona el resultado final. Al iniciar en (6.0, -6.0), el algoritmo converge hacia un mínimo local ubicado en la región inferior derecha del mapa de contorno.

A diferencia de los experimentos anteriores, aquí se observa que la topografía de la función $f(X, Y)$ no es convexa (no tiene un solo "hoyo"). La superficie presenta al menos cuatro valles claramente definidos. Al cambiar el punto de inicio a una zona alejada, la

"gravedad" del gradiente arrastra la trayectoria hacia el pozo más cercano, demostrando que el algoritmo es localmente dependiente.

Respuestas a las Preguntas: Fase 2

1. Dependencia del Punto Inicial

¿El algoritmo llega siempre al mismo punto final? No. Como se observa al comparar tus gráficas, el punto final depende totalmente de la región donde inicie la búsqueda.

Explicación topográfica: La función presenta múltiples mínimos locales. El descenso del gradiente es un optimizador local; esto significa que "baja por la pendiente más cercana". Si la topografía tiene varios valles, el algoritmo quedará atrapado en el primero que encuentre, sin saber si existe un valle más profundo (mínimo global) en otra parte del mapa.

2. El fenómeno de "Overshooting"

Explicación física: Ocurre cuando el producto de la tasa de aprendizaje por genera un vector de desplazamiento cuya magnitud es mayor que la distancia geométrica al fondo del valle. Es como si un esquiador bajara una montaña a tanta velocidad que, al llegar al fondo, su propia inercia lo hiciera subir por la ladera opuesta.

Visualización en curvas de nivel: Se observa como un zigzag o rebote entre las paredes de las curvas de nivel. Si el η es muy alto, los saltos se vuelven cada vez más grandes, alejándose del centro (divergencia).

3. Eficiencia Computacional

Estrategia recomendada: Si tras 1000 iteraciones el algoritmo sigue lejos y se mueve muy lento, la mejor estrategia suele ser ajustar (aumentar ligeramente) la tasa de aprendizaje.

Aumentar las iteraciones simplemente permite que el algoritmo siga caminando "a paso de tortuga", lo cual consume tiempo de cómputo innecesario. Al ajustar η , aumentamos la

longitud del paso, permitiendo que el algoritmo cubra más distancia en menos iteraciones, siempre cuidando de no caer en el overshooting.

4. Generalización (Ingeniería)

¿Por qué es peligroso confiar en un único punto de inicio?

En problemas de cientos de variables (como logística o redes neuronales), el "paisaje" de la función de costo es increíblemente complejo, lleno de miles de mínimos locales y puntos de silla. Confiar en un solo inicio aleatorio es como intentar encontrar el punto más bajo de todo el Himalaya soltando a una persona en un lugar al azar: lo más probable es que se quede atrapada en un valle pequeño y nunca encuentre la base real de la cordillera.

suelen usar técnicas como Multi-start o algoritmos con Momentum para explorar mejor el espacio

Fase 3

Vista rapida (head)

index	instant	dteday	season	yr	mnth	hr	holiday	weekday	workingday	weathersit	temp	atemp	hum	windspeed	casual	registered	cnt
0	1	2011-01-01 00:00:00	1	0	1	0	0	6	0	1	0.24	0.2879	0.81	0.0	3	13	16
1	2	2011-01-01 00:00:00	1	0	1	1	0	6	0	1	0.22	0.2727	0.8	0.0	8	32	40
2	3	2011-01-01 00:00:00	1	0	1	2	0	6	0	1	0.22	0.2727	0.8	0.0	5	27	32
3	4	2011-01-01 00:00:00	1	0	1	3	0	6	0	1	0.24	0.2879	0.75	0.0	3	10	13
4	5	2011-01-01 00:00:00	1	0	1	4	0	6	0	1	0.24	0.2879	0.75	0.0	0	1	1

Imagen 2

Overview




Figura 5 Resumen estadístico del conjunto de datos de bicicletas compartidas

El resumen muestra las estadísticas descriptivas y los tipos de variables del dataset analizado. Adaptado de *Bike Sharing Dataset*, por H. Fanaee-T y J. Gama, 2013.

Variables




Figura 6 Perfil estadístico detallado de la variable 'instant'

El resumen muestra las estadísticas descriptivas específicas y la distribución de la variable de índice instant.





Figura 7 Perfil estadístico de las variables temporales 'dteday' y 'season'

El resumen detalla el rango de fechas y la distribución de las estaciones climáticas en el conjunto de datos.




Figura 8 Distribución de frecuencias para las variables cnt (conteo total) y temp (temperatura)

El histograma superior muestra una distribución con sesgo positivo para la demanda de bicicletas, mientras que el histograma inferior refleja una distribución multimodal de la

temperatura normalizada. Adaptado de *Bike Sharing Dataset*, por H. Fanaee-T y J. Gama, 2013.




Figura 9 Distribución de frecuencias para las variables atemp (sensación térmica) y hum (humedad)

El histograma superior ilustra la sensación térmica percibida por los usuarios, mostrando una distribución multimodal normalizada. El histograma inferior presenta la distribución de la humedad relativa, destacando un sesgo hacia condiciones de humedad media-alta. Adaptado de *Bike Sharing Dataset*, por H. Fanaee-T y J. Gama, 2013.




Figura 10 Tendencias promedio de alquiler de bicicletas por hora y día de la semana

El gráfico superior muestra el comportamiento bimodal de la demanda horaria, con picos en horas de entrada y salida laboral. El gráfico inferior presenta la variación del promedio de alquileres según el día de la semana (0 = domingo, 6 = sábado). Adaptado de *Bike Sharing Dataset*, por H. Fanaee-T y J. Gama, 2013.




Figura 11 Gráfico de dispersión de valores reales vs. predichos (Conjunto de Test) mediante un modelo MLP

La gráfica muestra la precisión de la red neuronal Multi-Layer Perceptron al predecir el conteo de bicicletas. La línea discontinua representa la predicción perfecta ($y = x$). Adaptado de *Bike Sharing Dataset*, por H. Fanaee-T y J. Gama, 2013.




Figura 12 Distribución de los residuales del modelo MLP en el conjunto de prueba

El histograma muestra la diferencia entre los valores reales y las predicciones. Una distribución centrada en cero indica la ausencia de sesgo sistemático en el modelo. Adaptado de *Bike Sharing Dataset*, por H. Fanaee-T y J. Gama, 2013.




Figura 13 Curva de pérdida del modelo MLP durante la fase de entrenamiento

La gráfica ilustra la reducción de la función de pérdida a lo largo de 200 iteraciones, mostrando una rápida convergencia inicial y una estabilización posterior del error. Adaptado de *Bike Sharing Dataset*, por H. Fanaee-T y J. Gama, 2013.

Fase 3: Análisis Avanzado de Resultados (MLP)

A. Diferenciación de Métricas: MAE vs. RMSE

La elección entre estas métricas no es solo estética; define qué tanto "castigamos" la imprecisión del modelo.

Error Absoluto Medio (MAE): Matemáticamente, se define como. $MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$
Al usar el valor absoluto, el MAE ofrece una medida de la magnitud del error promedio sin importar su dirección. Es una métrica robusta ante valores atípicos, tratándolos de forma lineal.

Raíz del Error Cuadrático Medio (RMSE): Se define como

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

debido a que el error se eleva al cuadrado antes de promediarse, los errores grandes tienen un impacto desproporcionadamente alto en el resultado final.

Análisis de Severidad:

El RMSE penaliza con mayor severidad los errores grandes (outliers). En el contexto de las ventas o el alquiler de bicicletas, esto es crucial: un error de predicción de 500 unidades en una sola hora es logísticamente mucho más catastrófico (falta total de stock o colapso del sistema) que tener 5 errores pequeños de 100 unidades distribuidos en el día. Por lo tanto, si el

RMSE es significativamente mayor al MAE, sabemos que nuestro modelo está cometiendo "pocos fallos, pero muy grandes".

B. Diagnóstico de Desempeño: El Fenómeno del Sobreajuste

Cuando el coeficiente de determinación (R^2) en el conjunto de entrenamiento es marcadamente superior al del conjunto de prueba, nos enfrentamos al fenómeno de Sobreajuste (Overfitting).

Análisis Técnico: El Perceptrón Multicapa ha aprendido el "ruido" y las fluctuaciones aleatorias de la muestra de entrenamiento en lugar de la tendencia subyacente. En términos de sesgo-varianza, el modelo tiene una alta varianza.

Propuesta de solución basada en la Fase 1: * Selección de Variables (Feature Selection): Eliminar variables que el análisis exploratorio mostró como irrelevantes o altamente correlacionadas (como `instant` o `atemp` si ya usamos `temp`), reduciendo la dimensionalidad y el ruido que el modelo intenta memorizar.

Reducción de Complejidad: Si la arquitectura de la red es muy densa (ej. demasiadas neuronas en las capas ocultas), el modelo tiene demasiada "capacidad" y tiende a memorizar. Se recomienda reducir el número de neuronas o capas.

Regularización L2 (Weight Decay): Aplicar una penalización a los pesos de las neuronas para evitar que el modelo se vuelva excesivamente dependiente de una sola característica.

Para un análisis de nivel académico o profesional, es necesario profundizar en las implicaciones matemáticas y estadísticas de cada resultado. Aquí tienes una respuesta extendida y técnica para tu taller de Redes Neuronales.

Fase 3: Análisis Avanzado de Resultados (MLP)

A. Diferenciación de Métricas: MAE vs. RMSE

La elección entre estas métricas no es solo estética; define qué tanto "castigamos" la imprecisión del modelo.

Error Absoluto Medio (MAE): Matemáticamente, se define como. Al usar el valor absoluto, el MAE ofrece una medida de la magnitud del error promedio sin importar su dirección. Es una métrica robusta ante valores atípicos, tratándolos de forma lineal.

Raíz del Error Cuadrático Medio (RMSE): Se define como. Debido a que el error se eleva al cuadrado antes de promediarse, los errores grandes tienen un impacto desproporcionadamente alto en el resultado final.

Análisis de Severidad

El RMSE penaliza con mayor severidad los errores grandes (*outliers*). En el contexto de las ventas o el alquiler de bicicletas, esto es crucial: un error de predicción de 500 unidades en una sola hora es logísticamente mucho más catastrófico (falta total de stock o colapso del sistema) que tener 5 errores pequeños de 100 unidades distribuidos en el día. Por lo tanto, si el

RMSE es significativamente mayor al MAE, sabemos que nuestro modelo está cometiendo "pocos fallos, pero muy grandes".

B. Diagnóstico de Desempeño: El Fenómeno del Sobreajuste

Cuando el coeficiente de determinación (R^2) en el conjunto de entrenamiento es marcadamente superior al del conjunto de prueba, nos enfrentamos al fenómeno de Sobreajuste (Overfitting).

Análisis Técnico: El Perceptrón Multicapa ha aprendido el "ruido" y las fluctuaciones aleatorias de la muestra de entrenamiento en lugar de la tendencia subyacente. En términos de sesgo-varianza, el modelo tiene una alta varianza.

Propuesta de solución basada en la Fase 1: * Selección de Variables (Feature Selection)

Eliminar variables que el análisis exploratorio mostró como irrelevantes o altamente correlacionadas (como *instant* o *atemp* si ya usamos *temp*), reduciendo la dimensionalidad y el ruido que el modelo intenta memorizar.

Reducción de Complejidad: Si la arquitectura de la red es muy densa (ej. demasiadas neuronas en las capas ocultas), el modelo tiene demasiada "capacidad" y tiende a memorizar. Se recomienda reducir el número de neuronas o capas.

Regularización L2 (Weight Decay): Aplicar una penalización a los pesos de las neuronas para evitar que el modelo se vuelva excesivamente dependiente de una sola característica.

C. Interpretación de Residuos: Sesgos en Ventas/Alquileres Altos

Al analizar la gráfica de y_{real} vs y_{pred} (TEST), se identifica un patrón de error sistemático de subestimación.

- Observación Visual: La nube de puntos tiende a curvarse por debajo de la línea ideal ($y=x$) a medida que el valor de y_{real} aumenta (especialmente por encima de 600 alquileres).

Análisis del porqué: Esto suele ocurrir por dos razones:

- Distribución de la variable objetivo: Como vimos en el histograma de cnt, hay muy pocos registros con valores extremadamente altos (cola larga a la derecha). El modelo MLP, al intentar minimizar la función de pérdida global, se vuelve "conservador" y tiende a predecir

valores más cercanos a la media, ya que tiene menos ejemplos para aprender las condiciones que generan picos de demanda.

- Límite de la arquitectura: La configuración actual de la red neuronal puede no ser lo suficientemente compleja para capturar las interacciones no lineales extremas que ocurren durante las horas pico de mayor afluencia.
- Consecuencia práctica: El modelo es excelente para predecir la operación diaria normal, pero falla como sistema de alerta para días de demanda extraordinaria, lo que podría llevar a una infraestimación del servicio necesario en momentos críticos.

Fase 4

Fase 4

Datos

$$x = (0.5, 0.3, 0.2)^T$$

Capa 1

$$w^{(1)} = \begin{pmatrix} 0.2 & 0.5 & -0.1 \\ 0.8 & -0.3 & 0.4 \\ -0.5 & 0.1 & 0.2 \end{pmatrix}, b^{(1)} = \begin{pmatrix} 0.1 \\ -0.2 \\ 0.0 \end{pmatrix}$$

Capa 2

$$w^{(2)} = \begin{pmatrix} 0.5 & -0.4 & 0.1 \\ 0.2 & 0.8 & -0.5 \\ -0.1 & 0.3 & 0.7 \end{pmatrix}, b^{(2)} = \begin{pmatrix} -0.1 \\ 0.2 \\ 0.1 \end{pmatrix}$$

$$\text{Capa oculta } z_1^{(1)} = w^{(1)} x + b^{(1)}$$

Neurona 1

$$0.2(0.5) + 0.5(0.3) + (-0.1)(0.2) = 0.1 + 0.15 - 0.02 = 0.23$$

$$z_1^{(1)} = 0.23 + 0.1 = 0.33$$

Neurona 2

$$0.8(0.5) + (-0.3)(0.3) + 0.4(0.2) = 0.4 - 0.09 + 0.08 = 0.39$$

$$z_2^{(1)} = 0.39 - 0.2 = 0.19$$

Neurona 3

$$-0.5(0.5) + 0.1(0.3) + 0.2(0.2) = -0.25 + 0.03 + 0.04 = -0.18$$

$$z_3^{(1)} = -0.18 + 0 = -0.18$$

$$Z^{(1)} = (0.33, 0.19, -0.18)^T$$

D / M / A

Sigmoide $A^{(1)}$

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

$$\sigma(0,33) \approx 0,582$$

$$\sigma(0,19) \approx 0,547$$

$$\sigma(-0,18) \approx 0,455$$

$$A^{(1)} \approx (0,582, 0,547, 0,455)^T$$

Capa de Salida $Z^{(2)} = w^{(2)} \cdot A^{(1)} + b^{(2)}$

Neurona 1

$$0,5(0,582) + 0,4(0,547) + 0,1(0,455)$$

$$= 0,291 + 0,219 + 0,0455 = 0,5555$$

$$Z_1^{(2)} = 0,5555 - 0,1 = 0,4555$$

Neurona 2

$$0,2(0,582) + 0,8(0,547) - 0,5(0,455)$$

$$= 0,1164 + 0,4376 - 0,2275 = 0,3265$$

$$Z_2^{(2)} = 0,3265 + 0,2 = 0,5265$$

Neurona 3

$$-0,1(0,582) + 0,3(0,547) + 0,7(0,455)$$

$$= -0,0582 + 0,1641 + 0,3185 = 0,4244$$

$$Z_3^{(2)} = 0,4244 + 0,1 = 0,5244$$

$$Z^{(2)} = (0,4555, 0,5265, 0,5244)^T$$

Softmax (Probabilidades)

$$\text{Softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^3 e^{z_j}}$$



Imagen 4 Fase 4.2

$$e^{0.018} \approx 1.018$$

$$e^{0.527} \approx 1.693$$

$$e^{0.524} \approx 1.689$$

$$\text{Suma} = 1,018 + 1,693 + 1,689 = 4,400$$

Probabilidad

$$P_1 = \frac{108}{4400} = 0,231$$

$$P_2 = \frac{1693}{4400} = 0,385$$

$$P_3 = \frac{1689}{4400} = 0,384$$

$$(P_1, P_2, P_3) = ((0,231), (0,385), (0,384))$$

Respuestas Preguntas

1. la mayor probabilidad es P_2 0,385 o por lo tanto, la red clasifica la compañía como "impacto medio (Clase 2)".

2. Utilizamos Softmax en la última capa porque convierte los valores en probabilidades reales, todas las salidas son positivas y suman exactamente 1, esto permite interpretar la salida como una distribución de probabilidad.

Que pasaría si es una función lineal, no se limitarían los valores y no se podría interpretar como probabilidades.

Que pasaría si es sigmoide, cada salida estaría entre 0 y 1 pero no garantiza que sumen 1, no hay competencia entre clases.

3. **Rol del Bias**, si todos los bias fueran 0, la red perdería capacidad de representación, ya que las neuronas no podrían ajustarse libremente, reduciendo la precisión del modelo.

Imagen 6 Fase 4.5

Fase 5

Index	DI	Product ID	Type	Air temperature [K]	Process temperature [K]	Rotational speed [rpm]	Torque [Nm]	Tool wear [min]	Machine failure	WF	DF	WF	SF	NF
		14860		98.1	88.6	551	2.8							
		47181		98.2	88.7	408	6.3							
		47182		98.1	88.5	498	9.4							
		47183		98.2	88.6	433	9.5							
		47184		98.2	88.7	408	0.0							

Tabla 1 Recolección de datos




Figura 14 Análisis de distribución de clases

Nota. se presenta la distribución de la variable dependiente *Machine failure* (falla de maquinaria). De un total de 10,000 observaciones analizadas, se observa un marcado desbalance entre las clases. La clase mayoritaria, que representa el funcionamiento normal de los equipos (0 = No Falla), cuenta con 9,661 registros. Por el contrario, la clase minoritaria,

correspondiente a la ocurrencia de una avería (1 = Falla), registra únicamente




Figura 15 Análisis de variables Torque VS Velocidad Rotacional en los sensores

Nota. El gráfico demuestra que los fallos no ocurren al azar, sino que están correlacionados con condiciones operativas específicas de velocidad y torque. Parece haber "zonas de riesgo" tanto en condiciones de alto torque y baja velocidad como en condiciones de alta velocidad con torque moderado, mientras que el rango medio parece ser el más seguro.




Figura 16 Distribución de la temperatura del aire y su relación con la falla de maquinaria

Nota. El gráfico muestra un histograma de frecuencias solapado con curvas de densidad. La curva naranja indica que la concentración de fallos se desplaza hacia el extremo derecho del espectro térmico, evidenciando una correlación positiva entre el aumento de temperatura y la incidencia de averías.




Figura 17 Distribución de la temperatura del proceso según el estado de falla de la maquinaria

Nota. El histograma ilustra la frecuencia de las observaciones, mientras que las curvas de densidad de kernel (KDE) permiten comparar el comportamiento de ambas clases. Se evidencia que los eventos de falla (en naranja) se concentran preferentemente en el rango de temperaturas más elevadas del proceso.




Figura 18 Matriz de confusión del modelo Random Forest para la clasificación de fallos

Nota. Los cuadrantes de la diagonal principal representan las predicciones correctas. El valor de 0 en el cuadrante superior derecho indica la ausencia de falsos positivos, mientras que el valor de 3 en el cuadrante inferior izquierdo representa los fallos no detectados por el sistema.





Figura 19 Gráfico de importancia de las variables para el modelo Random Forest

Nota. El gráfico de barras horizontales clasifica las variables desde la mayor hasta la menor contribución al modelo. La longitud de la barra indica la importancia relativa, destacando la velocidad rotacional y el torque como los ejes fundamentales para el diagnóstico de fallas.



dense_2 (Dense)	(None, 1)	17
-----------------	-----------	----

Tabla 2 Resumen de la Arquitectura de la red neuronal

Respuesta de preguntas

Ajuste de Pesos de Clase y Entrenamiento de la Red Neuronal

Debido al desbalance de clases identificado previamente (3.39% de fallos), se implementó una técnica de balanceo mediante el ajuste de pesos en la función de pérdida. Se asignó un peso de $w_0 = 0.51$ para la clase normal y un peso de $w_1 = 14.76$ para la clase de fallo. Este ajuste tiene como objetivo mitigar el sesgo del modelo hacia la clase mayoritaria, penalizando con una severidad 14.7 veces superior los errores de omisión de fallas (falsos negativos).

Como se observa en el registro de entrenamiento (ver logs de salida), la red neuronal mostró una convergencia acelerada. El parámetro *Recall* en el conjunto de validación alcanzó el 100% desde las etapas tempranas del entrenamiento, manteniendo una precisión (*accuracy*) cercana a la unidad. Este comportamiento confirma que la ponderación de clases permitió al algoritmo capturar eficazmente las características de la clase minoritaria, garantizando que el sistema de mantenimiento predictivo sea altamente sensible a las anomalías críticas del proceso.

Si el *val_accuracy* y el *val_Recall* son ambos 1.0000, el modelo ha alcanzado la perfección técnica en este set de datos. En un entorno real, esto podría sugerir overfitting (sobreajuste), pero para un trabajo académico con datos sintéticos de mantenimiento, es un

resultado excelente que demuestra que las variables (Torque, RPM, Temp) son predictores muy potentes.

La Trampa de la Exactitud en Datos Desbalanceados

En el análisis de modelos predictivos aplicados al mantenimiento industrial, surge un fenómeno crítico conocido como la "trampa de la exactitud". Como se observó en la distribución inicial de los datos (Figura 1), la clase mayoritaria representa el 96.61% del total. En este escenario, una métrica de exactitud (*accuracy*) del 95% resultaría deficiente y potencialmente peligrosa para la gestión operativa.

Dicha deficiencia radica en que un modelo podría alcanzar ese porcentaje de acierto simplemente clasificando todas las instancias como "No Falla". Aunque el indicador estadístico parezca positivo, el modelo tendría una sensibilidad (*recall*) de cero, fallando en su propósito fundamental: la detección temprana de averías. Para la gestión de mantenimiento, el costo de omitir un fallo (falso negativo) implica paradas de producción no programadas y reparaciones correctivas costosas, los cuales superan significativamente el costo de una inspección preventiva derivada de una falsa alarma (falso positivo). Por consiguiente, el éxito del modelo no debe medirse por su exactitud global, sino por su capacidad de identificar correctamente la clase minoritaria, validada a través de la matriz de confusión y la métrica de *recall*.

Cálculo de Métricas y Análisis de Costos

Basado en los valores de la matriz de confusión del modelo Random Forest:

Verdaderos Positivos (TP): 65

Falsos Positivos (FP): 0

Falsos Negativos (FN): 3

Verdaderos Negativos (TN): 1932

Precision (Precisión)

Mide qué tan confiable es el modelo cuando emite una alerta.

$$\text{Precisión} = \frac{TP}{TP + FP} = \frac{65}{65 + 0} = 1 \rightarrow 100\%$$

Respuesta: El modelo es totalmente confiable. Si el sistema emite una alerta de falla, existe una seguridad del 100% de que la máquina realmente presenta un problema.

Recall (Sensibilidad)

Mide qué porcentaje de los fallos reales totales logró capturar el modelo.

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{65}{65 + 3} = 0.9558 \rightarrow 95.58\%$$

Respuesta: El modelo logra capturar el 95.58% de los fallos reales. Es una métrica excelente, aunque indica que un 4.42% de los fallos aún pasan desapercibidos.

Costo Total de Error

Impacto económico mensual basado en los errores del modelo.

Costo FN = \$5,000 USD

Costo FP = \$200 USD

$$\text{Costo} = (FN \times 5000) + (FP \times 200)$$

$$\text{Costo} = (3 \times 5000) + (0 \times 200) = 15.000 + 0 = \$15.000 \text{ USD}$$

Respuesta

El impacto económico de los errores del modelo es de \$15,000 USD mensuales, debido exclusivamente a los fallos no detectados.

Preguntas de Reflexión y Negocio (Fase 5)

¿Preferiría un modelo con un *Recall* del 98% pero una *Precision* del 60%, o viceversa?

Preferiría el modelo con Recall del 98%, En este contexto industrial, un fallo no detectado cuesta \$5,000, mientras que una falsa alarma solo cuesta \$200. Es preferible tener una precisión baja (muchas inspecciones innecesarias de \$200) si eso garantiza que

detectaremos casi todos los fallos críticos de \$5,000. Matemáticamente, evitar un solo fallo adicional justifica pagar por 25 inspecciones falsas.

¿Considera que 30 épocas son suficientes para que el modelo converja? ¿Qué sucede con el error de validación?

Sí, 30 épocas son suficientes. Al observar los logs de entrenamiento de la Red Neuronal, notamos que la pérdida (loss) disminuye drásticamente en las primeras 10 épocas y luego se estabiliza. El error de validación se mantiene muy cerca del error de entrenamiento (y el val_accuracy llega a 1.0000), lo que indica que el modelo convergió de manera óptima sin presentar overfitting (sobreajuste).

¿Cómo puede el uso de métricas avanzadas transformar la rentabilidad de una empresa?

El uso del Recall y el análisis de Costos de Error permite a la gerencia pasar de un mantenimiento correctivo (caro y reactivo) a uno predictivo basado en riesgos financieros. Al entender que no todos los errores valen lo mismo, la empresa puede configurar sus modelos de IA para maximizar el ahorro, priorizando la detección de paradas críticas sobre la simple exactitud estadística, transformando así el departamento de mantenimiento en un centro de optimización de costos y rentabilidad.

CONCLUSIONES

A partir del desarrollo de las diferentes fases del taller, se evidenció la importancia de comprender tanto los fundamentos teóricos como las implicaciones prácticas de los modelos de aprendizaje automático en entornos industriales.

En primer lugar, la regularización Ridge demostró ser una herramienta clave para garantizar la estabilidad de los modelos de regresión, especialmente en escenarios con alta correlación entre variables o alta dimensionalidad. Su aplicación permite controlar el

sobreajuste mediante el equilibrio entre sesgo y varianza, lo cual es fundamental para mejorar la capacidad de generalización.

En segundo lugar, el análisis del algoritmo de descenso del gradiente permitió identificar la relevancia de la tasa de aprendizaje y el punto inicial en la convergencia del modelo. Se evidenció que valores inadecuados pueden generar problemas como divergencia o lentitud extrema, afectando la eficiencia computacional.

En el caso del modelo MLP aplicado a la predicción de la demanda de bicicletas, se concluye que, aunque el modelo presenta un buen desempeño general, existen limitaciones en la predicción de valores extremos debido a la distribución de los datos y la complejidad del modelo. Esto resalta la necesidad de un adecuado preprocesamiento y selección de variables.

Por otro lado, en el contexto de mantenimiento predictivo, se comprobó que el uso de métricas como el Recall es más relevante que la exactitud en escenarios con datos desbalanceados. La minimización de falsos negativos resulta crítica, ya que estos representan altos costos operativos para las empresas.

Finalmente, se concluye que el uso de modelos de inteligencia artificial, acompañado de un análisis adecuado de métricas y costos, permite transformar la gestión empresarial, pasando de enfoques reactivos a estrategias predictivas que optimizan recursos, reducen riesgos y mejoran la rentabilidad.

REFERENCIAS

- Fanaee-T, H., & Gama, J. (2013). *Event labeling combining ensemble detectors and background knowledge*. University of Porto. (Bike Sharing Dataset)
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, É. (2011).
- Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning* (2nd ed.). Springer.
- Géron, A. (2022). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly Media.

